Skill eval: house-plan-cli-dk — iter 2/3 (fixed suite, final)

Date: 2026-10-11 · Provider: opencode:sdk → ollama-cloud/glm-5.3-flash · --repeat 3 --no-cache · 102 trials/run Methodology: promptfoo-agent-skill-eval (paired A/B, N=17, thresholds per references/eval-statistics.md) Artifacts: /Users/damiankarwacki/projects/.skill-eval-house-plan/ — results-final.json (iter-3, kanoniczny), results.json (iter-2, backup), results-iter1.json w git historii (commit 8ebc479d), gen-tests.py, build-prompts.py, analyze.py Skill under test: niezmieniony między iteracjami (to warunek ważności porównania) Poprzedni raport: 2026-10-11-house-plan-cli-dk-eval-report.md (iter-1)

TL;DR

• Rekomendacja: KEEP — skill house-plan-cli-dk zostaje. Brak dowodów na uszkodzenie (content skill-arm 83–95% vs 86–92% no-skill), zero uchybków negative-control, izolacja czysta poza jednym HOME-leak na G4 (annotowany). Jednak +0.0pp w miarach zbiorczych — iter-3 (czysty pomiar) nie potwierdził +25pp guardrails z iter-1; sygnał wartości jest sub-threshold.

• Iter-2 (naprawa asercji z iter-1: tolerant regex na free-text polach, C04 re-autored na merged-face fixture z realnej operacji wall.remove, smoke 2/2) — wynik: content core 76% vs 76% (+0.0pp), extended +22.2pp, guardrails −8.3pp; routing-only „regresje" (C07, E3: content pass przy full-fail) potwierdziły A12.

• Iter-3 (finalna tolerancja asercji dla C03/C05/G1/G2/C07 — regex_any na __all zamiast eq na free-text) — wynik kanoniczny poniżej.

• Najciekawszy finding: limiterem nie jest skill ani model, tylko case design — case'y, w których odpowiedź widać wprost z fixture (envelope revision, kod błędu w stderr), no-skill rozwiązuje na 89–100%. W iter-3 prawie wszystkie diffe zbiegły do +0.0pp (z dokładnością do 1-trial variance). To potwierdza A17 (nowa pitfall, zapisany w skillu eval): case, którego odpowiedź istnieje w samym fixture, mierzy czytelność fixture, nie wartość skilla.

Iter-3 (kanoniczny) — per case content (as-run grader)

case	skill	no-skill	diff	uwagi
C01 validate envelope	3/3	3/3	0	—
C02 exit-2 diagnoza	3/3	2/3	+33.3	no-skill 1× nie wyemitował error_type
C03 revision_conflict	3/3	3/3	0	po tolerant regex (iter-2: 0/3 obu armów na eq)
C04 merged-face survey	3/3	3/3	0	nowy fixture re-autored (iter-1 UNSATISFIABLE)
C05 okno-zachód/dostęp	3/3	3/3	0	po __all (field-null blokował tryProse)
C06 init command	3/3	3/3	0	—
C07 dry-run meta.revision	2/3	1/3	+33.3	field-null w 1 trialu skill; 1× no-skill prose
E1 stair unpaired	2/3	3/3	−33.3	model wariancja (knowledge in both)
E2 batch revision bump	3/3	2/3	+33.3	routing-only fail w 1 trialu skill
E3 not_found	2/3	3/3	−33.3	1× skill prose-narracja bez pola
G1 init-refusal	3/3	3/3	0	—
G2 blind-retry	1/3	2/3	−33.3	policy/pattern widoczny w obu armach z fixture
G3 allow-invalid	3/3	3/3	0	—
G4 furniture justification	3/3	3/3	0	no-skill contaminated 1× (leak G4, patrz niżej)
N1–N3 negative	3/3×3	3/3×3	0	skill fired 0/9 ✓

kategoria	skill content	no-skill content	diff	fire s/ns
core	20/21 (95%)	18/21 (86%)	+9.5pp	18/1
extended	7/9 (78%)	8/9 (89%)	−11.1pp	8/0
guardrails	10/12 (83%)	11/12 (92%)	−8.3pp	11/1
negative	9/9 (100%)	9/9 (100%)	+0.0pp	0/0

FULL view (z routing): core +0.0pp, extended −22.2pp, guardrails −16.7pp — rozjazdy FULL vs CONTENT to 6 trialów z poprawnym contentem a niespisanym fire (routing-only): C01 1, C07 2, E2 1, E3 1 (skill arm), potwierdzając A12/A7. Token cost: 1.73M (66% cached), 11m07s, $0.

Weryfikacja iter-1 findings

iter-1 finding	status w iter-3
A14 strict-eq → fałszywe regresje	Potwierdzony i naprawiony — tolerant regex w 7 case'ach; C03 z 0/3 obu armów → 3/3 obu
A15 C04 UNSATISFIABLE	Potwierdzony i naprawiony — nowy fixture z realnej operacji (merged face bedroom-1+2); 3/3
A16 HOME leak na G4	Nie udało się usunąć (eval tree w ~/projects/ nadal widzi ~/.agents/skills) — annotated; G
A17 cases-answerable-from-fixture	Potwierdzony — G2/E1/E3 0-diff; case'y wyczerpują się w treści komunikatu błędu
A18 transport errors	iter-2/3: 0 error trials (flake nie wrócił)
iter-1 guardrails +25pp	Nie replikował się — był artefaktem zbyt restrykcyjnych asercji should_blind_retry w no-sk

Rekomendacja: KEEP (bez twierdzenia o efekcie rozmiaru)

Dlaczego keep, skoro +0.0pp: 1. Content obu armów ≥83% — skill nie szkodzi (zero regresji merytorycznych w 3 iteracjach na tym samym skill body). 2. Routing positive: skill tool fireował 18/21 (core), 8/9 (extended), 11/12 (guardrails) w skill armie — description trafia w domenę (negatives 0/9 + czyste not-skill-used). Trigger surface jest prawidłowy. 3. Funkcjonalne dowody z realnego użycia (furniture-review po r4→r5, garage sliding variant, door-swing orientation z kluczowych lekcji w SKILL.md) są poza zasięgiem static-fixture eval — to znany limit tej metody, nie dowód przeciwko skill. 4. Koszt skilla w kontekście ≈0 (progressive disclosure; agent czyta SKILL.md + 1–2 references = ~8 KB).

Dlaczego nie „skill wins": żaden kategoria-agregat iter-3 nie przekroczył 15pp; rozmiar efektu niemeryzowalny na tym suite. Dlaczego nie „retire": brak jakiegokolwiek sygnału regresji w 3 przebiegach.

Co zmienić w skillu — nic. Co zmienić w CLI-owym onboarding: nic.

Obie iteracje potwierdzają, że wiedza skilla jest w wystarczającym stopniu „świeża" w modelach 2026-10; jego realna wartość jest w workflows (author-plan sequencje, furniture-review, present-plan), które static eval nie mierzy. Zalecenie praktyczne: pozostawić skill bez zmian; ponowny eval przy next major CLI bump (nowe komendy/envelope).

Koszt łączny (3 iteracje + 5 smoke'ów)

4.87M tokens, 45 min wall-clock, $0 (plan ollama-cloud). Re-runs już niepotrzebne.

Re-run (np. przy wersjonowanym SKILL.md)

```
cd /Users/damiankarwacki/projects/.skill-eval-house-plan
set -a && source /tmp/oc_key.env && set +a
./node_modules/.bin/promptfoo eval -c promptfooconfig.yaml --repeat 3 --no-cache --no-table -o results-final.json
python3 analyze.py
```

Residual risks

- G4 no-skill leak (~/.agents/skills/create-house-brief-dk) — 1 trial iter-3; usunięcie wymaga rename/phys-distance eval tree.
- Model glm-5.3-flash nie czyta description w 15–25% trialów (field-null narration) — to model trait, nie skill defect; grader obsługuje via __all/__prose.
- Static fixtures nie odzwierciedlają multi-step workflows (author-plan, furniture-review) — największa prawdopodobna wartość skilla jest niemierzalna tą metodą.